

Report IUM - Data Analysis

Componenti del gruppo:

- Bedino Edoardo - matricola: 997518
- Candela Davide - matricola: 976529
- Kostadinov Iliyan - matricola: 979118

Link alla repo **GitLab**: <https://gitlab2.educ.di.unito.it/st214128/assignment-ium-tweb>

NOTA: Noi siamo il gruppo che le ha mandato la mail relativa al problema di rinominare la main directory con i nostri cognomi. Non siamo riusciti a trovare una soluzione e per tanto quando scaricherà da GitLab il nostro progetto, esso sarà contenuto in una directory chiamata nel seguente modo: assignment-ium-tweb.

Introduzione

Ispirati da "[Moneyball](#)", il film in cui Brad Pitt veste i panni di Billy Beane, un general manager che trasforma la squadra di baseball Oakland Athletics attraverso un approccio basato su dati statistici, ci poniamo la domanda: come potremmo noi, nei panni di allenatori di calcio, utilizzare un metodo simile per scegliere i giocatori più adatti e costruire una squadra vincente? Abbiamo deciso di esplorare questa strategia, valutando l'efficacia di una selezione basata sui numeri per ottenere successo in campo.

Technical Tasks

1. Pulizia dei dati

a. Soluzione

Ci siamo concentrati sulla pulizia dei file .csv a nostra disposizione, decidendo in particolare di non considerare completamente il file club_games.csv. Infatti, a parer nostro, le informazioni all'interno di club_games erano facilmente recuperabili dagli altri dataset. Di seguito l'elenco delle modifiche fatte durante la pulizia dei dati:

- **Dati dei Club:**
 - rimozione di colonne irrilevanti
 - conversione dei valori monetari
 - gestione dei valori mancanti
 - controllo dei duplicati
 - assicurazione della validità dei dati
 - per le capacità degli stadi
 - gli anni delle stagioni calcistiche
 - che il numero dei giocatori stranieri e il numero dei giocatori che giocano in nazionale sia minore del numero totale dei componenti della squadra
- **Dati dei Giocatori:**
 - rimozione di colonne irrilevanti
 - gestione dei valori mancanti
 - correzione dei tipi di dati geografici
- **Dati delle Valutazioni dei Giocatori:**
 - rimozione di colonne irrilevanti

- gestione dei valori mancanti
- normalizzazione del formato delle date
- **Dati delle Partite:**
 - rimozione di colonne irrilevanti
 - gestione dei valori mancanti
 - assicurazione della correttezza delle date delle partite
 - normalizzazione del formato delle date
 - eliminazione di record duplicati
 - verifica dell'integrità delle informazioni
 - non ci possono essere delle squadre che giocano una partita sia come squadra ospite che come squadra di casa
 - non si possono avere un numero di spettatori negativo
- **Dati degli Eventi delle Partite:**
 - rimozione di colonne irrilevanti
 - gestione dei valori mancanti
 - assicurazione della correttezza delle date delle partite
 - verifica dell'integrità delle informazioni sul minutaggio dell'evento
- **Dati delle Presenze:**
 - gestione dei valori mancanti
 - controllo dei duplicati
 - controllo dell'integrità delle informazioni
 - non ci possono essere dei goal negativi
 - non ci possono essere degli assist negativi
 - non ci possono essere più di due cartellini gialli o più di un cartellino rosso
- **Dati delle Competizioni:**
 - eliminazione di colonne non necessarie
 - controllo dei duplicati
 - controllo dei valori mancanti
- **Dati delle Formazioni di Gioco:**
 - conversione di valori stringa in numerici dove applicabile
 - gestione di duplicati
 - gestione dei valori mancanti
 - controllo dell'integrità delle informazioni sui capitani

Ogni dataset pertanto è stato analizzato e sovrascritto con le nuove modifiche e le nuove informazioni con i dati puliti.

b. Problemi

Indubbiamente, la parte più complessa della pulizia dei dati è stata la gestione dei valori nulli. Spesso non è stato facile decidere come trattare i dati mancanti, poiché si richiede una comprensione approfondita dei dati stessi e del contesto in cui vengono utilizzati. Rimuovere semplicemente i valori nulli può portare ad una perdita significativa di informazioni, mentre riempirli in modo inappropriato può distorcere i risultati dell'analisi. Talvolta, ad esempio per i valori numerici, abbiamo utilizzato la media o la mediana come sostituti. La media è stata utilizzata quando i dati erano distribuiti in modo simmetrico, mentre la mediana è stata preferita per le distribuzioni asimmetriche o quando i dati contenevano outlier. Altre volte invece si è preferito gestire i valori mancanti numerici, sostituendoli con il valore "-1". Questo approccio ha permesso di mantenere l'integrità dei dati e di ridurre al minimo l'eliminazione di tuple.

c. Requisiti

Al termine della pulizia dei dati, ogni dataset pulito viene salvato in un nuovo csv ben strutturato e pronto per essere analizzato ed elaborato. Tutti i valori precedentemente nulli possiedono un nuovo valore, le colonne non rilevanti nei dataset per le analisi sono state scartate, mentre quelli in formati non desiderati sono stati adattati alle nostre esigenze. In questo modo abbiamo ottenuto una buona qualità e affidabilità dei dati, i quali saranno pronti ad essere analizzati.

d. Limitazioni

Talvolta, per evitare di eliminare completamente delle porzioni di dataset, abbiamo gestito i valori nulli con un valore sentinella (come ad esempio “unknown” per le stringhe o “-1” per i valori numerici). Vi è pertanto la necessità, in fase di analisi del dataset, di fare un ulteriore controllo sulle colonne in cui sono stati inseriti i valori sentinella. Abbiamo però deciso di adottare questa strategia per essere coerenti con alcune colonne già presenti nel dataset fornito: ad esempio, in `games_event.csv`, per i valori in cui il minuto dell’evento non è stato registrato, è presente il numero -1.

1. Analisi Statistica

a. Soluzione

Per i punti elencati successivamente, abbiamo realizzato una fase di estrapolazione dei dati, dai dataset puliti precedentemente, necessari alla risposta del quesito posto. In questo modo abbiamo tagliato una porzione del dataset non necessaria alla nostra valutazione. Successivamente abbiamo costruito e aggiunto al dataset diverse colonne utili all’analisi del punto trattato (merge con altri dataset oppure creazione di nuove colonne basate su calcoli matematici). Una volta che la struttura finale è stata raggiunta, abbiamo sfruttato le librerie di *matplotlib*, *seaborn* e *geopandas* per visualizzare al meglio la conclusione tratta. Sotto ogni grafico mostrato è presente un commento esplicativo.

Per lo svolgimento delle nostre analisi ci siamo finti degli allenatori esperti di calcio che devono prendere decisioni per la propria squadra. Per scegliere quali passi si deve intraprendere per rendere una squadra competitiva a livello europeo sono stati analizzati i dati a nostra disposizione per generare delle informazioni utili. In particolare ci siamo concentrati sulle seguenti domande:

1. Quale formazione scegliamo per la nostra squadra?
2. Quale correlazione c'è fra nazione e valore di valutazione medio più alto per posizione?
3. Come gestire le sostituzioni durante la partita?
4. Quali caratteristiche fisiche devono avere i giocatori per ogni posizione?
5. Quali caratteristiche deve avere il rigorista?
6. Quali caratteristiche hanno statisticamente i giocatori sostituiti a causa di un infortunio?
7. Di quale età media deve essere la nostra squadra?
8. Quale è la dimensione giusta per lo stadio?
9. Quali sono le nazioni con i giocatori più esperti e con le migliori valutazioni di mercato?
10. Quali caratteristiche deve avere un capitano?
11. Quanto budget di mercato bisogna riservare per ogni ruolo?
12. Quando è corretto sostituire un giocatore ammonito?
13. Come varia la valutazione economica dei giocatori in base alla nazionalità?
14. Quali caratteristiche deve avere un tiratore di punizioni?

b. Problemi

Non essendo degli esperti di analisi statistica, ci siamo trovati in difficoltà nel riuscire ad estrapolare delle informazioni utili dai dati a nostra disposizione. Talvolta infatti le nostre analisi si limitavano semplicemente ad essere delle semplici rappresentazioni di dati, senza effettivamente fare inferenza.

Inoltre è stato anche complesso comprendere a pieno la struttura di un dataset che è stato ideato ed organizzato da persone esterne al nostro gruppo.

c. Requisiti

Abbiamo utilizzato tutti gli strumenti e le tecniche mostrate durante le lezioni/esercitazioni in laboratorio. Nello specifico come costruire un dataframe prendendo più informazioni da differenti dataset, eseguire calcoli matematici su particolari valori (percentuali, medie, mediane, correlazioni) e visualizzare il tutto su un grafico appropriato.

d. Limitazioni

Ci sono indubbiamente delle limitazioni legate alla struttura e all'ideazione del dataset. Infatti il nostro universo preso in considerazione si limita a rappresentare solamente una porzione del mondo reale. Ad esempio, dei giocatori che militano in una squadra che partecipa ad una competizione extraeuropea vengono completamente tagliati fuori dalla nostra visione d'insieme, risultando di fatto come ritirati.

Molte statistiche inoltre sono decisamente influenzate dalla differenza di presenza dei giocatori di una nazione, causando (ovviamente) delle differenze in fase di analisi.

Conclusioni e divisione del lavoro:

Bedino: quesiti età media della squadra, dimensione grandezza stadio, nazioni con giocatori più esperti e con le migliori valutazioni di mercato, caratteristiche del capitano

Candela: quesiti su formazioni, budget di mercato per ruolo, sostituzione giocatore ammonito, tiratore punizione, valutazione economica in base alla nazionalità.

Kostadinov: quesiti su correlazione fra nazione e valore di valutazione, sostituzioni, caratteristiche fisiche per posizione, caratteristiche del rigorista

Ogni membro del gruppo ha indagato, sviluppato e visualizzato 4/5 quesiti posti dall'elenco citato precedentemente. In questo modo il proprio lavoro diventa indipendente e personale dal lavoro altrui, senza che si formino situazioni di stallo che possano ostruire la continuazione delle analisi. Ci sono state però situazioni in cui qualche membro del gruppo ha prestato supporto su un quesito non appartenente al suo interesse. Riteniamo in ogni caso che il lavoro sia stato suddiviso adeguatamente e che il numero di grafici ottenuti per ciascun membro sia bilanciato. Infine è stata realizzata un'ulteriore revisione di tutti i grafici per rendere il progetto il più coerente e uniforme possibile.

Bibliografia

<https://chatgpt.com/>